


April 30, 2025

CNC 머신 데이터를 활용한 불량 예측 모델 개발



요고4조요고4조(4조)

남동진 한광호 송이현 김보미 정해현



팀원 소개




남동진

EDA
XGBoost 모델 개발




한광호

EDA
GBM 모델 개발
실패 케이스 분석



송이현

EDA
LightGBM 모델 개발
DNN, CNN 모델 개발



김보미

EDA
CatBoost 모델 개발
실패 케이스 분석



정해현

EDA
AdaBoost 모델 개발
파생변수 분석

목차

01

추진 배경

03

프로젝트 목표

05

데이터 전처리 및
분석 결과

07

딥러닝 모델

02

문제 상황

04

데이터 설명 및 속성 값

06

머신러닝 모델

08


인사이트



추진 배경

01

Global CNC Machine Tools Market Size
2033 (USD Billion)



출처 - CNC 공작 기계 시장 규모

글로벌 CNC 공작기계 시장은 2024년 677억 달러, 2033년 1,39,85억 달러에 이를 것으로 예상되며, 예측 기간 동안 약 2배 이상 성장할 것으로 보임.

02

IT·과학

車부품 공장에 AI 혁신 ... "공구 언제 고장날지 미리 알려줘요"


“CNC 장비의 절삭가공 시 발생하는 공구 부하 데이터를 학습해 최적의 공구 교체 시점을 제시하는 AI 기반 수명예측 시스템을 개발 중이다.”

(출처: 매일경제, 2022.11.07)


AI 기술이 제조업 공정에서 정확도와 생산성을 향상시키는 주요 트렌드로 자리 잡고 있으며, 공정 최적화와 불량 예측, 공구 수명 예측에 중요한 역할을 하고 있음.

추진 배경

CNC 머신은 컴퓨터 수치 제어 (Computer Numerical Control) 기계를 뜻하며, 컴퓨터 프로그램을 이용하여 기계의 움직임을 자동으로 제어하는 자동화된 공작 기계로, 다양한 분야에서 금속, 플라스틱 등의 재료를 다양한 공구로 깎아 가공하는 데 사용함.



문제 상황



프로젝트 목표

- 양품/불량품 데이터의 특징 파악
 - 공정 개선 방향 도출
 - 다양한 AI 모델을 통해 양품/불량품 예측
-



데이터 설명 및 속성 값

- 제조 분야 : 자동차 부품
- 제조 공정명 : 자동차 부품 CNC 가공 공정
- 수집 데이터 : 공장 내 CNC 가공 장비 Data, 조건 및 품질 Data
- 수집 기간 : 10/19~10/23 (5일)
- 수집 주기 : 1 sec

1개의 조건 및 품질 Data 와 25번의 작업에서 측정한 센서 Data

총 26개의 Table

데이터 설명 및 속성 값

조건 및 품질 Data

Input Data	Description
No	작업 번호
material	작업 소재
feed rate	Tool 이동 속도 (mm/s)
clamp pressure	소재 Clamping 압력 (bar)
Output Data	Description
tool condition	일정시간 사용한 Tool, 새로운 Tool
machining_finalized	공정 완료 여부
passed_visual_inspection	육안검사(품질검사) 통과 여부

특정 작업에서 사용된
절삭 공구의 상태,
가공 완료 여부,
육안검사 통과 여부
등을 확인할 수 있음

데이터 설명 및 속성 값

조건 및 품질 Data

Input Data	Description
No	작업 번호
material	작업 소재
feed rate	Tool 이동 속도 (mm/s)
clamp pressure	소재 Clamping 압력 (bar)
Output Data	Description
tool condition	일정시간 사용한 Tool, 새로운 Tool
machining_finalized	공정 완료 여부
passed_visual_inspection	육안검사(품질검사) 통과 여부

양품/불량품 분류 기준

공정 완료 & 육안검사 통과 ▶ 양품

공정 완료 & 육안검사 불통 ▶ 불량품

공정 미완료 ▶ 불량품

데이터 설명 및 속성 값

공장 내 CNC 가공 장비 Data

Data Set	Number of row
experiment_01.csv	1056
experiment_02.csv	1669
experiment_03.csv	1522
experiment_04.csv	533
...	
experiment_23.csv	463
experiment_24.csv	2333
experiment_25.csv	566

25번의 공정에서 측정한 센서 데이터 테이블

데이터 설명 및 속성 값


공장 내 CNC 가공 장비 Data

Data Set	Number of row
experiment_01.csv	1056
experiment_02.csv	1669
experiment_03.csv	1522
experiment_04.csv	533
...	
experiment_23.csv	463
experiment_24.csv	2333
experiment_25.csv	566

CNC 실험 별 세팅값 Data

Attributes name	Description
X_ActualPosition	부품의 실제 x 위치
Y_ActualVelocity	부품의 실제 x 속도
Z_ActualAcceleration	부품의 실제 x 가속도
S_CurrentFeedback	스핀들 전류
...	
Machining_Process	현재 수행중인 가공 단계
M_CURRENT_PROGRAM_NUMBER	프로그램이 CNC에 나열된 번호

데이터 설명 및 속성 값



데이터 설명 및 속성 값

조건 및 품질 Data

Input Data	Description
No	작업 번호
material	작업 소재
feed rate	Tool 이동 속도 (mm/s)
clamp pressure	소재 Clamping 압력 (bar)
Output Data	Description
tool condition	일정시간 사용한 Tool, 새로운 Tool
machining_finalized	공정 완료 여부
passed_visual_inspection	육안검사(품질검사) 통과 여부

공장 내 CNC 가공 장비 Data

Data Set	Number of row
experiment_01.csv	1056
experiment_02.csv	1669
experiment_03.csv	1522
experiment_04.csv	533
...	
experiment_23.csv	463
experiment_24.csv	2333
experiment_25.csv	566

CNC 실험 별 세팅값 Data

Attributes name	Description
X_ActualPosition	부품의 실제 x 위치
Y_ActualVelocity	부품의 실제 x 속도
Z_ActualAcceleration	부품의 실제 x 가속도
S_CurrentFeedback	스핀들 전류
...	
Machining_Process	현재 수행중인 가공 단계
M_CURRENT_PROGRAM_NUMBER	프로그램이 CNC에 나열된 번호

문제 터 설명 및 속성 값

1. 각각의 센서 데이터가 서로 다른 공정에 대한 데이터

2. 시계열 분석을 통해 이상치를 측정하기엔 데이터의 수가 부족

가정

시계열 데이터가 아니라

각각의 행을 한개의 PRODUCT로 가정하고 분석 진행

Input Data	Description
material	작업 소재
feed rate	Tool 이동 속도 (mm/s)
clamping pressure	소재 Clamping 압력 (bar)

Output Data	Description
tool condition	설정시간 사용한 Tool, 새로운 Tool
passed visual inspection	육안검사(품질검사) 통과 여부

Data Set	Number of row
experiment_01.csv	1056
experiment_02.csv	1669
experiment_03.csv	1522
experiment_04.csv	533
...	
experiment_23.csv	463
experiment_24.csv	1335
experiment_25.csv	566

Attributes name	Description
X_ActualPosition	부품의 실제 x 위치
Y_ActualVelocity	부품의 실제 x 속도
Z_ActualAcceleration	부품의 실제 x 가속도
S_CurrentFeedback	스핀들 전류
...	
Machining_Process	현재 수행중인 가공 단계
MACHINE_PROGRAM_NUMBER	프로그램이 CNC에 나열된 번호

데이터 전처리 및 분석 결과

```
concat_df.isnull().sum().sort_values(ascending=False)
```

✓ 0.0s


X_ActualPosition	0
Z_SetPosition	0
Z_SetAcceleration	0
Z_CurrentFeedback	0
Z_DCBusVoltage	0
Z_OutputCurrent	0
Z_OutputVoltage	0
S_ActualPosition	0
S_ActualVelocity	0
S_ActualAcceleration	0
S_SetPosition	0
S_SetVelocity	0
S_SetAcceleration	0
S_CurrentFeedback	0
S_DCBusVoltage	0
S_OutputCurrent	0
S_OutputVoltage	0
S_OutputPower	0
S_SystemInertia	0
M_CURRENT_PROGRAM_NUMBER	0
M_sequence_number	0
M_CURRENT_FEEDRATE	0
Machining_Process	0
Z_SetVelocity	0
Z_ActualAcceleration	0
...	
Y_OutputVoltage	0
Y_OutputPower	0
Z_ActualPosition	0
normal	0

제공 받은
데이터셋 자체가
1차 가공이 된
데이터로,
결측치 존재하지
않았음.


normal
1
1
1
1
1
...
0
0
0
0
0

공정 완료 및 육안 검사 합격
을 양품으로,
공정 미완료 혹은 공정 완료
및 육안 검사 불합격을 불량품
으로 정의하고,
데이터 셋 마지막 컬럼 뒤로
['normal'] 컬럼을 추가하여
양품을 1로, 불량품을 0으로
데이터 라벨링 진행.

데이터 전처리 및 분석 결과



양품(1): 70.7%, 불량품(0) : 29.3%
→ RAW DATA는 불균형 데이터



양품(1): 50%, 불량품(0) : 50%
→ SMOTE 기법을 통해
균형 데이터로 보정하여 과적합 방지

Attributes name	Description	단위
X_ActualPosition	부품의 실제 x 위치	mm
Y_DCBusVoltage	y전압	V
S_CurrentFeedback	스핀들 전류	A
S_SystemInertia	토크 관성	kg·m ²


생산 데이터들 간의 단위가 맞지 않으므로, 정규화가 필요함

`scaler = MinMaxScaler()`


→ MinMaxScaler()을 통해 데이터 보정 진행

데이터 전처리 및 분석 결과

X축 데이터




Y축 데이터




데이터 전처리 및 분석 결과

Z축 데이터







Spindle 데이터




데이터 전처리 및 분석 결과

Machine 데이터



머신러닝 - 분류 모델 선택


CatBoost



- 불량 예측률: 92.8%
($TN/(FP+TN)$)
- F1-SCORE: 96%




XGBoost



- 불량 예측률 : 92.5%
($TN/(FP+TN)$)
- F1-SCORE : 95%



LightGBM




- 불량 예측률 : 96.0%
($TN/(FP+TN)$)
- F1-SCORE : 95%



머신러닝 - 분류 모델 선택


GBM



- 불량 예측률 : 95.7%
($TN/(FP+TN)$)
- F1-SCORE: 95%
- FN : 132개




AdaBoost



- 불량 예측률 : 95.6%
($TN/(FP+TN)$)
- F1-SCORE: 95%
- FN : 102개



LightGBM




- 불량 예측률 : 96.0%
($TN/(FP+TN)$)
- F1-SCORE : 95%
- FN : 98개



머신러닝 - FEATURE IMPORTANCE


S_ACTUALPOSITION
M_CURRENT_FEEDRATE
S_SETACCELERATION
X_OUTPUTCURRENT
Y_OUTPUTCURRENT
S_SETVELOCITY
S_OUTPUTCURRENT
S_SYSTEMINERTIA
Z_ACTUALPOSITION
Z_SETPOSITION
X_ACTUALPOSITION
M_SEQUENCE_NUMBER
MACHINING_PROCESS
S_ACTUALVELOCITY
Y_ACTUALPOSITION
Y_DCBUSVOLTAGE
X_SETVELOCITY
X_DCBUSVOLTAGE
S_DCBUSVOLTAGE
S_SETPOSITION



불량 예측 실패 분석

1. SHAP 예측 중요 변수 상위 20개
 2. SHAP을 통한 불량 예측 실패 분석
 3. 예측 실패 분석 인사이트
-

SHAP 예측 중요 변수



✓ SHAP 모델은 예측 시, FEATURE의 영향 정도를 시각화하여 비교하는 기법

예측 영향이 큰 변수 3개

- M_CURRENT_FEEDRATE
- X_OutPutCurrent
- S_SetVelocity FEATURE


✓ M_CURRENT_FEEDRATE의 영향이 압도적!

예측 실패 분석

✓ WATERFALL PLOT : 모델 예측값을 단계별로 보여주는 시각화!


8

실패 케이스 1 (False Negative)



- $E[f(X)]$: 전체 데이터셋을 모델이 예측한 평균 값
- $f(x)$: 특정 샘플에 대해 모델이 최종적으로 예측한 값

실패 케이스 2 (False Positive)



M_CURRENT_FEEDRATE 강한 음의 영향 불량 예측 실패

예측 실패 분석 인사이드

항목	내용
주요 영향 변수	M_CURRENT_FEEDRATE, X_OutPutCurrent Feature
가장 큰 영향 변수	M_CURRENT_FEEDRATE 100개의 예측 실패 사례 모두 최소 -2 음의 영향을 크게 작용하고 있음!
실패 케이스 분석 이유	품질과 안정성을 높이고, 예측 실패 리스크를 줄이기 위해
의심 포인트	하나의 변수에 과도 의존성을 띤다, 특정 상황에서 리스크 집중 가능성이 있다
분석결과	특정 변수에 과도하게 의존하는 경향이 눈에 보였고, 그 때문에 예측 오류를 유발한 것으로 식별 됨

- ✓ M_CURRENT_FEEDRATE에 대한 과의존이 예측 실패의 주원인
- ✓ 모델 과의존 > 정상 오판 > 리스크 증가로 이어짐
- ✓ 성능 향상을 위해 최우선 변수로 고려



파생변수 분석

프로세스

1. 불량 예측 모델 선정 (LGBM)
2. SHAP 중요 변수 선정 (상위 20개)
3. 과학적 의미 고려한 파생변수 생성
4. 기존 df vs 파생 df 성능 비교
5. SHAP 중요도 비교 및 인사이트 도출


기대효과

1. 파생변수 추가 시
모델 성능 향상 예상
2. 보다 정교한 인사이트
확보 가능


생성된 파생변수

파생변수	수식	의미	기대 효과
Velocity_Current_Ratio (속도-전류 비율)	속도 / 전류	고속 + 과다 전류 → 비정상 부하	부하 증가, 공구 마모 감지
Velocity_Power_Ratio (속도-전력 비율)	속도 / 전력	에너지 효율성 지표	비효율적 가공 탐지
Torque_Estimate (토크 추정)	속도 × 전류	모터 힘(토크) 간접 추정	고토크 위험 감지
Load_Increase (로드 증가)	전류 / 속도	부하 급증 조짐 탐지	장비/소재 문제 조기 발견

SHAP를 통한 분석



기존



파생변수 병합

SHAP를 통한 분석

항목	파생변수 추가 전 (원본)	파생변수 추가 후
최상위 변수	M_CURRENT_FEEDRATE	Torque_Estimate (2등)
새롭게 등장한 변수	없음	Torque_Estimate, Load_Increase, Velocity_Current_Ratio
상위 중요도 변화	기존 변수 유지	파생변수 상위 진입
영향도 폭	-4 ~ +4	-6 ~ +6

- Torque_Estimate(속도×전류 기반 추정 토크)가 2등으로 상승 → 물리적 해석 변수의 강한 설명력 확인
- Load_Increase(전류/속도 비율) 등 이상 부하 감지 가능성 향상
- 일부 기존 변수(X_OutputCurrent 등)는 중요도가 소폭 하락
- 파생변수로 인한 SHAP 분포 폭 확대 → FAIL/PASS 예측 민감도 증가

파생변수 인사이트


- ✓ 파생변수 단독으로도 예측 성능 '우수'
- ✓ 그러나 기존 피처와 함께 써야 최적 성능

"파생변수는 '보조적 역할', 기존 변수와 시너지 필요"


파생함수 4개만

파생함수 병합


LightGBM



- 불량 예측률 : 93.6%
($TN/(FP+TN)$)
- F1-SCORE : 89%
- FN : 304개




- 불량 예측률 : 95.1%
($TN/(FP+TN)$)
- F1-SCORE: 95%
- FN : 104개



- 불량 예측률 : 96.0%
($TN/(FP+TN)$)
- F1-SCORE : 95%
- FN : 98개

딥러닝 - DNN



DNN(Deep Neural Network)
DNN은 은닉층을 2개 이상 지닌 학습 방법을
뜻하며,
컴퓨터가 스스로 분류레이블을 만들어 내고
공간을 왜곡하고 데이터를 구분짓는 과정을
반복하여
최적의 구분선을 도출해냄.

딥러닝 - DNN

모델 기본 구조

Model: "sequential"


Layer (type)	Output Shape	Param #
dense (Dense)	(None, 128)	6,272
dropout (Dropout)	(None, 128)	0
dense_1 (Dense)	(None, 256)	33,024
dropout_1 (Dropout)	(None, 256)	0
dense_2 (Dense)	(None, 512)	131,584
dropout_2 (Dropout)	(None, 512)	0
dense_3 (Dense)	(None, 512)	262,656
dropout_3 (Dropout)	(None, 512)	0
dense_4 (Dense)	(None, 256)	131,328
dropout_4 (Dropout)	(None, 256)	0
dense_5 (Dense)	(None, 128)	32,896
dropout_5 (Dropout)	(None, 128)	0
dense_6 (Dense)	(None, 2)	258

Total params: 598,018 (2.28 MB)

Trainable params: 598,018 (2.28 MB)

Non-trainable params: 0 (0.00 B)

에포크 30개 기준 정확도, 손실 그래프



→ 에포크 약 8~9 사이에서 과대적합 발생

EarlyStopping 기준 train, test 데이터의 손실과 정확도

```
1133/1133 ————— 1s 1ms/step - accuracy: 0.8907 - loss: 0.2265
201/201 ————— 0s 1ms/step - accuracy: 0.8817 - loss: 0.2381
```

```
([0.22758111357688904, 0.9144402742385864],
 [0.22583509981632233, 0.8870514631271362])
```

F1 Score: 0.8993

손실 : 0.226

정확도: 0.887, F1 Score : 0.8993

딥러닝 - DNN

**** 모두 EarlyStopping 사용 ****

변경 사항

- 학습률 $1e-4 \rightarrow 1e-3$ 으로 변경

개선된 모델

0.887 $\rightarrow$ 0.949

F1 Score: 0.9393

변경 사항

- 학습률 $1e-4 \rightarrow 1e-3$ 으로 변경
- Drop Out 간소화
- 'binary_crossentropy' 에서
'categorical_crossentropy'로 손실 함수 변경
- 1024 $\rightarrow$ 512 배치 사이즈 변경

개선된 모델

0.887 $\rightarrow$ 0.960

F1 Score: 0.9531

변경 사항

- Dropout 위치 및 비율 조정
- Drop Out 간소화
- Learning Rate Scheduler (학습률을 동적으로 변경)
사용
- 배치사이즈 변경 (1024 $\rightarrow$ 256, 1024 $\rightarrow$ 128)

개선된 모델

0.887 $\rightarrow$ 0.962 (배치 : 256)

F1 Score: 0.9531

0.887 $\rightarrow$ 0.967(배치 : 128)

F1 Score: 0.9531


딥러닝 - DNN

최종 모델 구조

Model: "sequential_31"

Layer (type)	Output Shape	Param #
dense_200 (Dense)	(None, 128)	6,272
dense_201 (Dense)	(None, 256)	33,024
dense_202 (Dense)	(None, 512)	131,584
dropout_118 (Dropout)	(None, 512)	0
dense_203 (Dense)	(None, 256)	131,328
dropout_119 (Dropout)	(None, 256)	0
dense_204 (Dense)	(None, 128)	32,896
dense_205 (Dense)	(None, 2)	258

에포크 30개 기준 정확도,손실 그래프



→ 에포크 약 2~3 사이에서 과대적합 발생

EarlyStopping 기준 train, test 데이터의 손실과 정확도

```
1133/1133 _____ 1s 696us/step - accuracy: 0.9779 - loss: 0.0398
201/201 _____ 0s 711us/step - accuracy: 0.9664 - loss: 0.0570
```

```
( [0.03994658589363098, 0.978775680065155],
  [0.056449536234140396, 0.9672386646270752] )
```

F1 Score: 0.9531

손실 : 0.056

정확도: 0.967, F1 Score : 0.9531


Total params: 335,362 (1.28 MB)

Trainable params: 335,362 (1.28 MB)

Non-trainable params: 0 (0.00 B)

딥러닝 - CNN

<https://sehooni.github.io/dl/ANN,DNN,CNN,RNN/>



CNN(Convolution Neural Network, 합성곱신경망)

DNN은 데이터에서 정보를 추출해 학습이 이루어졌지만, CNN은 데이터의 특징을 추출하여 특징들의 패턴을 파악하는 구조이며, CNN 알고리즘은 Convolution Layer와 Pooling Layer가 복합적으로 구성됨.

*Convolution Layer : 파악한 특징을 한장으로 도출시키는 과정

*Pooling Layer : Convolution 과정을 거친 레이어의 사이즈를 줄여주는 과정


딥러닝 - CNN

공장 내 CNC 가공 장비 Data

Data Set	Number of row
experiment_01.csv	1056
experiment_02.csv	1669
experiment_03.csv	1522
experiment_04.csv	533
...	
experiment_22.csv	566
experiment_23.csv	463
experiment_24.csv	2333
experiment_25.csv	566

CNC 실험 별 세팅값 Data

Attributes name	Description
X_ActualPosition	부품의 실제 x 위치
Y_ActualVelocity	부품의 실제 x 속도
Z_ActualAcceleration	부품의 실제 x 가속도
...	
S_CurrentFeedback	스핀들 전류
...	
Machining_Process	스핀들의 순간 공급 속도
M_CURRENT_PROGRAM_NUMBER	프로그램이 CNC에 나열된 번호



1차원 신호 데이터를 STFT(Short-Time Fourier Transform) 를 적용해,
기존 train/test 데이터를 스펙트로그램 이미지로 변환하고 저장
→ 변환된 이미지는 CNN 기반 딥러닝 모델 입력으로 사용 가능

딥러닝 - CNN

1) Residual Block 구조

- 입력값을 그대로 더해주는 Skip Connection 사용
- 출력 = $F(x) + x$ 형태로, **잔차(Residual)**만 학습

2) 기울기 소실 문제 해결

- 깊은 층에서도 안정적으로 학습 가능

3) Degradation 문제 극복

- 층이 깊어질수록 오히려 성능이 떨어지던 기존 CNN의 문제 해결
- 매우 깊은 네트워크 구성 가능
- 고층 모델도 학습 안정성 확보

4) Bottleneck 구조

- $1 \times 1 \rightarrow 3 \times 3 \rightarrow 1 \times 1$ convolution으로 효율적 학습

5) 다양한 모델에 확장 적용

- Faster R-CNN, Mask R-CNN 등 다양한 비전 모델의 기반

CNN 모델 중 가장 대표적인 모델인 Resnet 사용

https://velog.io/@for1overson1y_/ResNet50

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
conv2_x	56×56	3×3 max pool, stride 2				
		$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$
conv4_x	14×14	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36$
conv5_x	7×7	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

Resnet 모델 중 50개의 layer를 가지고 있는 Resnet-50 사용

딥러닝 - CNN

모델 기본 구조


Model: "functional_3"

Layer (type)	Output Shape	Param #	Connected to
input_layer_3 (InputLayer)	(None, 224, 224, 3)	0	-
conv1_pad (ZeroPadding2D)	(None, 230, 230, 3)	0	input_layer_3[0]...
conv1_conv (Conv2D)	(None, 112, 112, 64)	9,472	conv1_pad[0][0]
conv1_bn (BatchNormalizatio...	(None, 112, 112, 64)	256	conv1_conv[0][0]
conv1_relu (Activation)	(None, 112, 112, 64)	0	conv1_bn[0][0]
pool1_pad (ZeroPadding2D)	(None, 114, 114, 64)	0	conv1_relu[0][0]
pool1_pool (MaxPooling2D)	(None, 56, 56, 64)	0	pool1_pad[0][0]
conv2_block1_1_conv (Conv2D)	(None, 56, 56, 64)	4,160	pool1_pool[0][0]
conv2_block1_1_bn (BatchNormalizatio...	(None, 56, 56, 64)	256	conv2_block1_1_c...
conv2_block1_1_relu (Activation)	(None, 56, 56, 64)	0	conv2_block1_1_b...
conv2_block1_2_conv (Conv2D)	(None, 56, 56, 64)	36,928	conv2_block1_1_r...
conv2_block1_2_bn (BatchNormalizatio...	(None, 56, 56, 64)	256	conv2_block1_2_c...
conv2_block1_2_relu (Activation)	(None, 56, 56, 64)	0	conv2_block1_2_b...
conv2_block1_0_conv (Conv2D)	(None, 56, 56, 256)	16,640	pool1_pool[0][0]
conv2_block1_3_conv (Conv2D)	(None, 56, 56, 256)	16,640	conv2_block1_2_r...
conv2_block1_0_bn (BatchNormalizatio...	(None, 56, 56, 256)	1,024	conv2_block1_0_c...
conv2_block1_3_bn (BatchNormalizatio...	(None, 56, 56, 256)	1,024	conv2_block1_3_c...
conv2_block1_add (Add)	(None, 56, 56, 256)	0	conv2_block1_0_b... conv2_block1_3_b...

(중략)

Total params: 76,957,576 (293.57 MB)
Trainable params: 25,634,818 (97.79 MB)
Non-trainable params: 53,120 (207.50 KB)
Optimizer params: 51,269,638 (195.58 MB)

에포크 10개 기준 정확도,손실 그래프



→ 에포크 약 1에서 과대적합 발생

EarlyStopping 기준 test 데이터의 손실과 정확도

Test loss: 0.2158

Test accuracy: 0.9103

Test F1 Score: 0.9358

손실 : 0.2158

정확도: 0.9103, F1 Score : 0.9358

딥러닝 - CNN

**** 모두 EarlyStopping 사용 ****

변경 사항

- 드롭아웃 추가

개선된 모델

0.9103 -> 0.9119

F1 Score: 0.9343

변경 사항

- 드롭아웃 추가
- 학습률 0.001 -> 0.0001으로 변경
- Adam에서 AdamW(Adam+ 가중치 감소 적용)으로 옵티마이저 변경

개선된 모델

0.9103 -> 0.9346

F1 Score: 0.9525

변경 사항

- 드롭아웃 추가
- 학습률 0.001 -> 0.0001으로 변경

개선된 모델

0.9103->0.9510

F1 Score: 0.9650

딥러닝 - CNN


최종 모델 구조

Layer (type)	Output Shape	Param #	Connected to
input_layer (InputLayer)	(None, 224, 224, 3)	0	-
conv1_pad (ZeroPadding2D)	(None, 230, 230, 3)	0	input_layer[0][0]
conv1_conv (Conv2D)	(None, 112, 112, 64)	9,472	conv1_pad[0][0]
conv1_bn (BatchNormalizatio...	(None, 112, 112, 64)	256	conv1_conv[0][0]
conv1_relu (Activation)	(None, 112, 112, 64)	0	conv1_bn[0][0]
pool1_pad (ZeroPadding2D)	(None, 114, 114, 64)	0	conv1_relu[0][0]
pool1_pool (MaxPooling2D)	(None, 56, 56, 64)	0	pool1_pad[0][0]
conv2_block1_1_conv (Conv2D)	(None, 56, 56, 64)	4,160	pool1_pool[0][0]
conv2_block1_1_bn (BatchNormalizatio...	(None, 56, 56, 64)	256	conv2_block1_1_c...
conv2_block1_1_relu (Activation)	(None, 56, 56, 64)	0	conv2_block1_1_b...
conv2_block1_2_conv (Conv2D)	(None, 56, 56, 64)	36,928	conv2_block1_1_r...
conv2_block1_2_bn (BatchNormalizatio...	(None, 56, 56, 64)	256	conv2_block1_2_c...
conv2_block1_2_relu (Activation)	(None, 56, 56, 64)	0	conv2_block1_2_b...

(중략)

Total params: 24,768,642 (94.48 MB)
Trainable params: 24,715,522 (94.28 MB)
Non-trainable params: 53,120 (207.50 KB)

에포크 10개 기준 정확도,손실 그래프



→ 에포크 약 3에서 과대적합 발생

EarlyStopping 기준 test 데이터의 손실과 정확도

Test loss: 0.1140
Test accuracy: 0.9510
Test F1 Score: 0.9650

손실 : 0.1140
정확도: 0.9510, F1 Score : 0.9650

인사이트

"단순 모델링을 넘어, 산업적 의미를 반영한 Feature Engineering과
실패 케이스 분석이 중요하며, 기계학습을 통한 성능 향상 가능성도 발견했다."

실패 분석 필요성

SHAP 기반 분석에서 예측 실패 케이스를 확인
→ 특정 Feature의 과의존이 예측 실패의 주 원인
→ 불량 탐지 모델 고도화를 위해 추가 분석 필수

파생변수의 힘

물리적 의미가 있는 파생변수가 단순 수치형 변수보다 강력한
설명력을 가짐
→ 공구 마모, 부하 증가 같은 현상을 조기에 감지할 수 있는
가능성

기계 학습 모델 가능성

머신러닝 모델도 우수했지만, DNN 적용 시 정확도 97%,
CNN 적용 시 F1-Score 97%까지 향상
→ 두 모델을 앙상블하면 각자의 강점을 살려 더 높은 예측
성능을 기대할 수 있음

감사합니다

